

## **Planos amostrais para seleção direta de elementos de uma população.**

A implementação dos planos amostrais descritos a seguir é motivada pela disponibilidade de um cadastro do tipo a).

Nesta parte, serão vistos os seguintes planos:

- Amostragem Aleatória Simples sem reposição - AAS
- Amostragem Sistemática - AS
- Amostragem de Bernoulli - BE
- Amostragem de Poisson - POI
- Amostragem com probabilidade proporcional ao tamanho - PPT
- Amostragem Estratificada - AE

## 7. Amostragem Aleatória Simples (sem reposição) - AAS

### Plano amostral

Um plano amostral AAS atribui probabilidade igual de seleção a toda amostra de tamanho  $n$  da população (de tamanho  $N$ ), a saber:

$$p(s) = \binom{N}{n}^{-1}.$$

Sob uma AAS, tem-se:

$$\pi_k = \frac{n}{N} \quad \text{e} \quad \pi_{kl} = \frac{n(n-1)}{N(N-1)}.$$

## Esquema amostral

Fan, Muller e Rezucha (1962)

Considere uma série de realizações independentes de uma Uniforme(0,1):

$$\varepsilon_1, \varepsilon_2, \varepsilon_3, \dots$$

Se  $\varepsilon_1 < \frac{n}{N}$ , então  $k=1 \in S$ ;

Senão,  $k=1 \notin S$

Para  $k = 2, 3, \dots$

Se  $\varepsilon_k < \frac{n - n_k}{N - k + 1}$ , então  $k \in S$ .

Senão,  $k \notin S$ .

$n_k$  é o número de elementos selecionados para compor a amostra dentre os primeiros  $k - 1$  elementos listados no cadastro.

O processo continua até que  $n_k = n$ .

## Estimação

Considere a estimação do total populacional de uma população finita sob um plano AAS.

**Resultado 7.1:** Sob uma AAS, o estimador de H-T assume a forma

$$\hat{t}_{\pi} = N\bar{y}_s$$

e tem como variância

$$Var_{AAS}(\hat{t}_{\pi}) = N^2(1-f)\frac{S_{yU}^2}{n}.$$

Além disso,

$$\hat{Var}_{AAS}(\hat{t}_{\pi}) = N^2(1-f)\frac{S_{ys}^2}{n}$$

é um estimador centrado para

$$Var_{AAS}(\hat{t}_{\pi}).$$

**Prova:**

Sobre a forma do estimador:

$$\hat{t}_{\pi} = \sum_{k \in S} \frac{y_k}{\pi_k} = \frac{N}{n} \sum_{k \in s} y_k = N \bar{y}_s ;$$

Sobre sua variância:

$$Var_p(\hat{t}_{\pi}) = \sum_{k \in U} \sum_{l \in U} \Delta_{kl} \frac{y_k}{\pi_k} \frac{y_l}{\pi_l}$$

Sob uma AAS,

$$\begin{aligned} \Delta_{kl} &= \pi_{kl} - \pi_k \pi_l = \frac{n(n-1)}{N(N-1)} - \left( \frac{n}{N} \right)^2 \\ &= \frac{n}{N} \left( \frac{n-1}{N-1} - \frac{n}{N} \right) \end{aligned}$$

$$\begin{aligned}
&= \frac{n}{N} \left( \frac{n}{N-1} - \frac{1}{N-1} - \frac{n}{N} \right) \\
&= \frac{n}{N} \left( -\frac{1}{N-1} + \frac{nN - n(N-1)}{N(N-1)} \right) \\
&= -\frac{1}{N-1} \left( \frac{n}{N} \right) \left( 1 - \frac{n}{N} \right).
\end{aligned}$$

Agora,

$$\begin{aligned}
Var_{AAS}(\hat{t}_\pi) &= \sum_{k \in U} \sum_{l \in U} \Delta_{kl} \frac{y_k}{\pi_k} \frac{y_l}{\pi_l} \\
&= \sum_{k \in U} \Delta_{kk} \left( \frac{y_k}{\pi_k} \right)^2 + \sum_{k \in U} \sum_{l \neq k \in U} \Delta_{kl} \frac{y_k}{\pi_k} \frac{y_l}{\pi_l}
\end{aligned}$$

$$\begin{aligned}
&= \frac{n}{N} \left( 1 - \frac{n}{N} \right) \sum_{k \in U} \left( \frac{y_k}{\pi_k} \right)^2 \\
&\quad - \frac{1}{N-1} \left( \frac{n}{N} \right) \left( 1 - \frac{n}{N} \right) \sum_{k \in U} \sum_{l \neq k \in U} \frac{y_k}{\pi_k} \frac{y_l}{\pi_l}
\end{aligned}$$

$$\begin{aligned}
&= \frac{n}{N} \left( 1 - \frac{n}{N} \right) \left( \frac{N}{n} \right)^2 \sum_{k \in U} y_k^2 \\
&\quad - \frac{1}{N-1} \left( \frac{n}{N} \right) \left( 1 - \frac{n}{N} \right) \left( \frac{N}{n} \right)^2 \sum_{k \in U} \sum_{l \neq k \in U} y_k y_l
\end{aligned}$$

$$\begin{aligned}
&= \left( 1 - \frac{n}{N} \right) \left( \frac{N}{n} \right) \frac{1}{N-1} \\
&\quad \times \left[ (N-1) \sum_{k \in U} y_k^2 - \sum_{k \in U} \sum_{l \neq k \in U} y_k y_l \right]
\end{aligned}$$



$$\begin{aligned}
&= \left(1 - \frac{n}{N}\right) \left(\frac{N}{n}\right) \frac{1}{N-1} \\
&\quad \times \left[ (N-1) \sum_{k \in U} y_k^2 - \left( \sum_{k \in U} y_k \right)^2 + \sum_{k \in U} y_k^2 \right] \\
&= \left(1 - \frac{n}{N}\right) \left(\frac{N}{n}\right) \frac{1}{N-1} \left[ N \sum_{k \in U} y_k^2 - \left( \sum_{k \in U} y_k \right)^2 \right] \\
&= \left(1 - \frac{n}{N}\right) \left(\frac{N^2}{n}\right) \frac{1}{N-1} \left[ \sum_{k \in U} y_k^2 - N \bar{y}_U^2 \right] \\
&= N^2 \left(1 - \frac{n}{N}\right) \frac{S_{yU}^2}{n}.
\end{aligned}$$

Sobre o estimador da variância:

A prova segue os mesmos passos do caso anterior.



## 7.1 Intervalos de confiança

Parâmetro de interesse:  $\theta$

Estimador centrado:  $\hat{\theta}$

Um intervalo de confiança para  $\theta$  consiste em um par de estatísticas

$$IC(s) \equiv [\hat{\theta}_L(s), \hat{\theta}_H(s)]$$

tal que  $\hat{\theta}_L(s) \leq \hat{\theta}_H(s)$  para toda amostra  $s$ .

Associado a cada intervalo de confiança, existe uma probabilidade de cobertura (nível de confiança):

$$Prob[IC(s) \ni \theta] = 1 - \alpha.$$

Assim, um  $IC(1 - \alpha)$  para um parâmetro  $\theta$  consiste em um intervalo obtido por um procedimento tal que garante uma probabilidade  $(1 - \alpha)$  de que o intervalo cobrirá o valor de  $\theta$ .

Num contexto de população finita, a probabilidade de cobertura de um  $IC(1 - \alpha)$  é interpretada em função do plano amostral  $p(s)$ , como segue.

Imagine que o valor de  $\theta$  fosse conhecido e defina os seguintes conjuntos:

$$\mathfrak{S} = \mathfrak{S}_b \cup \mathfrak{S}_b^c$$

$$\mathfrak{S}_b = \{s \in \mathfrak{S} : IC(s) \ni \theta\}$$

Assim, a probabilidade de cobertura do intervalo é dada por:

$$Prob[IC(s) \ni \theta] = 1 - \alpha \quad ,$$

onde

$$\alpha = \sum_{s \in \mathfrak{S}_b^c} p(s) .$$

## Uso na prática:

Na prática, o valor verdadeiro de  $\theta$  é desconhecido. O intervalo de confiança para  $\theta$  é construído considerando

$$\frac{\hat{\theta} - \theta}{\sqrt{\hat{Var}_p(\hat{\theta})}} \approx N(0, 1)$$

$$\therefore IC(1 - \alpha) \equiv \hat{\theta} \pm z_{\alpha/2} \sqrt{\hat{Var}_p(\hat{\theta})},$$

onde  $z_{\alpha/2}$  é uma constante tal que  $Prob(Z > z_{\alpha/2}) = \alpha/2$ ,  $Z \sim N(0, 1)$ .

Com base no procedimento acima, a probabilidade de cobertura do intervalo é, aproximadamente,  $1 - \alpha$ .

A qualidade dessa aproximação depende de duas condições:

1.  $\hat{\theta} \sim N(\theta, Var_p(\hat{\theta}))$ .

2.  $\hat{Var}_p(\hat{\theta})$  ser um estimador consistente de  $Var_p(\hat{\theta})$

$$\frac{\hat{\theta} - \theta}{\sqrt{\hat{Var}_p(\hat{\theta})}} = \frac{\hat{\theta} - \theta}{\sqrt{Var_p(\hat{\theta})}} \times \sqrt{\frac{Var_p(\hat{\theta})}{\hat{Var}_p(\hat{\theta})}}$$

## 7.2 O Teorema Central do Limite de Erdős, Rényi e Hájek

Denote por  $U_\zeta$  o subconjunto de  $U$  onde é verificada a desigualdade

$$(y_k - \bar{y}_U) > \zeta \sqrt{\text{Var}_{AAS}(\bar{y}_s)}.$$

Estabeleça ainda a seguinte notação:

$$W_{n, N-n} = \frac{\bar{y}_s - \bar{y}_U}{\sqrt{\text{Var}_{AAS}(\bar{y}_s)}}.$$

Então, quando  $n \rightarrow \infty$  e  $N-n \rightarrow \infty$ , tem-se que

$$W_{n, N-n} \xrightarrow{D} Z, \quad Z \sim N(0, 1)$$

desde que  $\lim_{n, N-n \rightarrow \infty} \frac{\sum_{k \in U_\zeta} (y_k - \bar{y}_U)^2}{\sum_{k \in U} (y_k - \bar{y}_U)^2} = 0$

para qualquer  $\zeta > 0$ .

**Prova:**

Omitida



## Comentários:

- Erdős e Rényi (1959) mostraram que a condição do teorema é suficiente.  
Hajék (1960) mostrou que a condição é necessária.
- A respeito do problema de quão grande deve ser a amostra para que o TCL seja aplicado, Cochran (1977, pág. 42) indica como regra:

$$n \geq 25 G_1^2,$$

$$\text{onde } G_1 = \frac{\sum_{k \in U} (y_k - \bar{y}_U)^3}{N S_{yU}^3} \text{ e}$$

$$S_{yU}^2 = (N-1)^{-1} \sum_{k \in U} (y_k - \bar{y}_U)^2.$$

- Em amostras pequenas, o intervalo de confiança é calculado usando  $t_{\alpha/2}$  no lugar de  $z_{\alpha/2}$ , onde a constante  $t_{\alpha/2}$  é tal que  $Prob(T > t_{\alpha/2}) = \alpha/2$ , com  $T \sim t_{(n-1)}$ .

### **7.3 Definições de estimadores consistentes e assintoticamente centrados no contexto de amostragem de populações finitas.**

Parâmetro de interesse:  $\theta$

**Definições usadas em um curso de inferência:**

Considere o problema de estimar  $\theta$  via um estimador  $\hat{\theta}_n$ , que seja função de  $n$  variáveis aleatórias i.i.d:

$$\hat{\theta}_n = \hat{\theta}_n(Y_1, \dots, Y_n)$$

## Estimador assintoticamente centrado:

(Definição usada em cursos de inferência estatística)

O estimador  $\hat{\theta}_n$  (entenda-se a seqüência de estimadores  $\hat{\theta}_1, \hat{\theta}_2, \dots$ ) é dito ser um estimador assintoticamente centrado para  $\theta$ , se

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta.$$

## Estimador consistente:

(Definição usada em cursos de inferência estatística)

O estimador  $\hat{\theta}_n$  (entenda-se a seqüência de estimadores  $\hat{\theta}_1, \hat{\theta}_2, \dots$ ) é dito ser um estimador consistente para  $\theta$ , se

$$\lim_{n \rightarrow \infty} Prob(|\hat{\theta}_n - \theta| > \epsilon) = 0.$$

Essas definições não fazem sentido em um contexto de inferência para uma população finita.

### **Definições usadas em um curso de amostragem:**

Para definir consistência e centralidade assintótica em amostragem de populações finitas, o seguinte cenário é utilizado:

Considere uma sequência infinita de elementos  $k = 1, 2, \dots$  e de valores  $y_1, y_2, \dots$  tal que  $y_k$  represente o valor da variável de interesse  $y$  associado ao elemento  $k$ .

Considere ainda uma seqüência de populações  $U_1, U_2, \dots$ , onde

$$U_v = \{1, 2, \dots, N_v\}$$

com  $N_{v+1} > N_v \quad \forall \quad v = 1, 2, \dots$

Assim, note que  $U_1 \subset U_2 \subset U_3 \subset \dots$

Defina o parâmetro de interesse

$$\theta_v = \theta_v(y_1, \dots, y_{N_v})$$

Imagine agora que uma amostra de  $n_v$  elementos seja retirada de  $U_v$  de acordo com o plano amostral  $p_v(\cdot)$  ( $n_v$  fixo e  $n_{v+1} > n_v \quad \forall \quad v = 1, 2, \dots$ ).

Note que, quando  $v \rightarrow \infty$ , tem-se  $n_v \rightarrow \infty$  e  $N_v \rightarrow \infty$ .

Seja  $\hat{\theta}_v = \hat{\theta}_v(\{y_k, \forall k \in S_v\})$  o estimador de  $\theta_v$  em questão.

Considerando as seqüências de populações e de planos amostrais descritas, tem-se as seguintes definições:

### Estimador assintoticamente centrado:

O estimador  $\hat{\theta}_v$  (entenda-se a seqüência de estimadores  $\hat{\theta}_1, \hat{\theta}_2, \dots$ ) é dito ser um estimador assintoticamente centrado se

$$\lim_{v \rightarrow \infty} [E_{p_v}(\hat{\theta}_v) - \theta_v] = 0.$$

### Estimador consistente:

O estimador  $\hat{\theta}_v$  (entenda-se a seqüência de estimadores  $\hat{\theta}_1, \hat{\theta}_2, \dots$ ) é dito ser um estimador consistente se

$$\lim_{v \rightarrow \infty} Prob(|\hat{\theta}_v - \theta_v| > \epsilon) = 0,$$

para qualquer  $\epsilon > 0$ .



## 7.4 Cálculo de tamanho de amostra

Parâmetro de interesse:  $\theta$

Estimador:  $\hat{\theta}$

Denote por  $d$  a margem de erro máxima admitida e, por  $\alpha$ , a probabilidade dessa margem ser excedida. O objetivo é determinar o tamanho  $n$  da amostra tal que

$$Prob(|\hat{\theta} - \theta| > d) < \alpha$$

Assumindo normalidade e centralidade de  $\hat{\theta}$ , tem-se que

$$\frac{\hat{\theta} - \theta}{\sqrt{Var_p(\hat{\theta})}} \sim N(0, 1)$$

Daí,

$$Prob\left(\frac{|\hat{\theta} - \theta|}{\sqrt{Var_p(\hat{\theta})}} > z_{\alpha}\right) = \alpha$$

Como a variância do estimador é função do tamanho da amostra, o valor de  $n$  é encontrado resolvendo a equação

$$z_{\alpha} \sqrt{Var_p(\hat{\theta})} \leq d$$

Para estimar o total populacional, por exemplo, sob uma AAS, pode-se verificar que

$$n = \left(\frac{1}{n_0} + \frac{1}{N}\right)^{-1}$$

onde 
$$n_0 = \frac{N^2 z_{\alpha}^2 S_{yU}^2}{d^2}.$$

## Uso na prática

Na prática, o valor de  $S_{yU}^2$  deve ser estimado. Isso pode ser feito por meio de uma amostra piloto ou recorrendo a informações de levantamentos passados.

## 8. Amostragem Sistemática - AS

### Plano amostral

Um plano amostral AS atribui probabilidade igual de seleção a um número limitado  $a$  de amostras de tamanho  $n$  da população (de tamanho  $N$ ), a saber:

$$p(s) = 1/a.$$

Sob uma AS, tem-se:

$$\pi_k = \frac{1}{a} \quad \text{e} \quad \pi_{kl} = \frac{1}{a} 1_{[k,l \in s]}.$$

## Esquema amostral

Fixe o valor de  $a$  de forma que  $n$  seja a parte inteira de  $N/a$ . Note que,

$$N = na + c,$$

onde  $c \in [0, a)$ . Se  $c = 0$ , o esquema amostral apresentado a seguir seleciona uma amostra de tamanho fixo,  $n$ . Do contrário, o tamanho da amostra pode vir a ser, também,  $n + 1$ .

- i. Selecione, com igual probabilidade, um inteiro  $r$ , onde  $1 \leq r \leq a$ .
- ii. A amostra será composta da seguinte forma:

$$s_r = \{k: k = r + (j - 1)a; j = 1, 2, \dots, n_s\},$$

com  $n_s = n$  quando  $r \leq c$  e  $n_s = n + 1$  quando  $c < r \leq a$ .

O espaço amostral é dado por:


$$\mathfrak{S} = \{s_1, s_2, \dots, s_a\}.$$

## Ilustração

Considere o caso simples em que  $N = 27$  e  $n = 9$ . Assim,  $a = 3$  ( $c = 0$ ).

A figura a seguir ilustra o esquema amostral assumindo  $r = 3$ .

Cada quadrado representa um elemento, listado no cadastro, na direção esquerda-direita.



## Estimação

Considere a estimação do total populacional de uma população finita, sob um plano AS.

A população tem uma estrutura peculiar evidenciada pelo esquema abaixo, para o caso em que  $c = 0$ :

$S_1$	...	$S_r$	...	$S_a$
$y_1$	...	$y_r$	...	$y_a$
$y_{1+a}$	...	$y_{r+a}$	...	$y_{2a}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$y_{1+(n-1)a}$	...	$y_{r+(n-1)a}$	...	$y_N$
$t_{S_1}$	...	$t_{S_r}$	...	$t_{S_a}$



**Resultado 8.1:** Sob uma AS, o estimador de H-T assume a forma

$$\hat{t}_{\pi} = a \sum_{k \in s} y_k = a t_s$$

e tem como variância

$$Var_{AS}(\hat{t}_{\pi}) = a(a-1)S_{yt}^2,$$

onde  $S_{yt}^2 = \frac{1}{a-1} \sum_{r=1}^a (t_{s_r} - \bar{t})^2$  e

$$\bar{t} = \frac{1}{a} \sum_{r=1}^a t_{s_r}.$$

**Prova:**

Sobre a forma do estimador:

$$\hat{t}_{\pi} = \sum_{k \in S} \frac{y_k}{\pi_k} = a \sum_{k \in S} y_k = a t_s ;$$

Sobre sua variância:

$$\begin{aligned} Var_p(\hat{t}_{\pi}) &= \sum_{k \in U} \sum_{l \in U} \Delta_{kl} \frac{y_k}{\pi_k} \frac{y_l}{\pi_l} \\ &= \sum_{k \in U} \sum_{l \in U} \left( \frac{\pi_{kl}}{\pi_k \pi_l} - 1 \right) y_k y_l \\ &= \sum_{k \in U} \sum_{l \in U} \frac{\pi_{kl}}{\pi_k \pi_l} y_k y_l - t^2 \\ &= \sum_{r=1}^a \left[ \sum_{k \in s_r} \sum_{l \in s_r} \frac{\pi_{kl}}{\pi_k \pi_l} y_k y_l \right] - t^2 \end{aligned}$$

Sob uma AS,

$$\frac{\pi_{kl}}{\pi_k \pi_l} = a, \text{ para } k, l \in s_r$$

$$\begin{aligned} \therefore Var_{AS}(\hat{t}_\pi) &= a \sum_{r=1}^a \left[ \sum_{k \in s_r} \sum_{l \in s_r} y_k y_l \right] - t^2 \\ &= a \sum_{r=1}^a t_{s_r}^2 - t^2 \\ &= a \left[ \sum_{r=1}^a t_{s_r}^2 - \frac{1}{a} t^2 \right] \\ &= a \sum_{r=1}^a (t_{s_r} - \bar{t})^2 \\ &= a(a-1)S_{yt}^2 \end{aligned}$$



## Comentários:

- O plano AS tem a vantagem de ser de fácil implementação. Se necessário, a amostra pode ser selecionada em campo.
- O plano AS pode ser usado para garantir dispersão geográfica de elementos selecionados.
- Apesar do plano AS ser de fácil implementação, o espaço amostral, comparado com o de um plano AAS, é bastante reduzido.
- Como  $\pi_{kl} = 0$ , para  $k, l \notin s$ , o plano AS não é mensurável.

- Por causa dessas limitações o plano AS é classificado, por alguns, como “quase-aleatório”.

Usando o esquema amostral proposto anteriormente, quando  $c > 0$ , o tamanho da amostra varia entre  $n$  e  $n + 1$  conforme  $r > c$  ou  $r \leq c$ , respectivamente.

Além disso, quando  $c = 0$ , em alguns casos, os tamanhos de amostra podem diferir muito daquilo que se planeja.

*Exemplo:* Suponha que o objetivo seja retirar uma amostra de tamanho  $n = 60$  de uma população com  $N = 149$  elementos. Usando  $a = 2$ , tem-se  $n = 74$  ou  $n = 75$ . Usando  $a = 3$ , tem-se  $n = 49$

ou  $n = 50$ . Tamanhos de amostra entre  $n = 50$  e  $n = 74$  não são possíveis.

O esquema amostral a seguir, contorna esse problema.

## 8.1 AS pelo método do intervalo fracionado

### Esquema amostral

Esse método seleciona uma AS através do uso de um valor fracionado de  $a$ , resultando em um tamanho de amostra  $n$ .

Defina  $a = \frac{N}{n}$ .

Considere  $\xi$ , uma realização de uma variável aleatória com distribuição uniforme em  $(0, a)$ .

A amostra será, então, composta pelos seguintes elementos:

$$S_r = \{k: k-1 < \xi + (j-1)a \leq k; j=1,2,\dots,n\}$$

**Exemplo:**

$$N = 21; \quad n = 5; \quad a = 4,2; \\ \xi = 2.1.$$

$j =$	1	2	3	4	5
$\xi + (j-1)a =$	2.1	6.3	10.5	14.7	18.9
$k \in s:$	3	7	11	15	19



**Resultado 8.2:** Usando o método do intervalo fracionado,

$$\pi_k = \frac{n}{N}.$$

**Prova:**

$$\begin{aligned}\pi_k &= \text{Prob}(k \in s) \\ &= \text{Prob}(k-1 < \xi + (j-1)a \leq k) \\ &= \frac{1}{a} = \frac{n}{N}\end{aligned}$$



O cálculo de  $\pi_{kl}$  requer mais trabalho. Os dois esquemas amostrais apresentados são equivalentes quando  $c=0$  e apresentam pouca diferença para valores grandes de  $N$ .

## 7.2 Análise da eficiência de um plano AS

Por simplicidade, considere o caso em que  $c=0$ . Nessa situação,  $a=N/n$ .

Logo,

$$\hat{t}_{\pi} = a t_s = N \bar{y}_{s_r}$$

e

$$Var_{AS}(\hat{t}_{\pi}) = Nn \sum_{r=1}^a (\bar{y}_{s_r} - \bar{y}_U)^2.$$

Por outro lado, note que

$$\sum_{k \in U} (y_k - \bar{y}_U)^2 = \sum_{r=1}^a \sum_{k \in s_r} (y_k - \bar{y}_{s_r})^2 + n \sum_{r=1}^a (\bar{y}_{s_r} - \bar{y}_U)^2$$

$$SQT = SQD + SQE$$

Fica claro, então, que

$$Var_{AS}(\hat{t}_{\pi}) = N \times SQE.$$

Defina agora a seguinte medida de homogeneidade:

$$\delta = 1 - \frac{N-1}{N-a} \frac{SQD}{SQT}.$$

Os valores extremos de  $\delta$  são:

$$\delta_{\min} = -\frac{a-1}{N-a}, \text{ quando } SQE = 0$$

$$\text{e } \delta_{\max} = 1, \text{ quando } SQD = 0.$$

É possível mostrar que, quando  $c = 0$   
(e  $a$  é um inteiro),

$$\begin{aligned} Var_{AS}(\hat{t}_{\pi}) &= \frac{N^2 S_{yU}^2}{n} [(1-f) + (n-1)\delta] \\ &= Var_{AAS}(\hat{t}_{\pi}) \left[ 1 + \frac{(n-1)}{(1-f)} \delta \right] \end{aligned}$$

$$\therefore deff(AS, \hat{t}_{\pi}) = \frac{Var_{AS}(\hat{t}_{\pi})}{Var_{AAS}(\hat{t}_{\pi})} = 1 + \frac{n-1}{1-f} \delta$$

Logo, AS será mais eficiente que AAS,  
apenas quando  $\delta < 0$ .

Essa situação ocorrerá dependendo da  
ordenação dos elementos na população.

## Exemplo:

Considere o caso em que  $N=20$  e  $n=4$  ( $a=4$ ). Suponha ainda que  $y_k = k$ .

Nesse caso,

$$Var_{AAS}(\hat{t}_{\pi}) = 20^2 \left(1 - \frac{4}{20}\right) \frac{35}{4} = 2.800,$$

independentemente de ordenação.

Os quadros (a), (b) e (c) a seguir ilustram o efeito da ordenação da população na eficiência de um plano AS:

Quadro (a)

$s_1$	$s_2$	$s_3$	$s_4$	$s_5$
1	2	3	4	5
10	9	8	7	6
11	12	13	14	15
20	19	18	17	16
42	42	42	42	42

$$Var_{AS}(\hat{t}_{\pi}) = N \times SQE = 20 \times 0 = 0$$

$$Var_{AAS}(\hat{t}_{\pi}) = 2.800$$

$$\delta = -\frac{a-1}{N-a} = -\frac{5-1}{20-5} = -0.2667$$

Quadro (b)

$s_1$	$s_2$	$s_3$	$s_4$	$s_5$
1	5	9	13	17
2	6	10	14	18
3	7	11	15	19
4	8	12	16	20
10	26	42	58	74

$$Var_{AS}(\hat{t}_{\pi}) = N \times SQE = 20 \times 640 = 12.800$$

$$Var_{AAS}(\hat{t}_{\pi}) = 2.800$$

$$\delta = 1 - \frac{N-1}{N-a} \frac{SQD}{SQT} \approx 0.95.$$

Quadro (c)

$s_1$	$s_2$	$s_3$	$s_4$	$s_5$
13	19	2	14	11
6	1	17	3	5
12	20	15	4	16
9	18	8	7	10
40	58	42	28	42

$$Var_{AS}(\hat{t}_{\pi}) = N \times SQE = 20 \times 114 = 2.280$$

$$Var_{AAS}(\hat{t}_{\pi}) = 2.800$$

$$\delta = 1 - \frac{N-1}{N-a} \frac{SQD}{SQT} \approx -0.05$$



### 8.3 Estimação de variância sob um plano AS

Sob o esquema amostral apresentado, não há estimador centrado para  $Var_{AS}(\hat{t}_{\pi})$ . Uma solução por vezes empregada é a utilização de  $\hat{Var}_{AAS}(\hat{t}_{\pi})$  para estimar  $Var_{AS}(\hat{t}_{\pi})$ . Porém, como visto, a menos que  $\delta = 0$ , este estimador pode ser bastante tendencioso.

Cochran (1977) apresenta alguns estimadores com base em modelos de superpopulação para as observações.

É possível derivar estimadores centrados para  $Var_{AS}(\hat{t}_{\pi})$  usando esquemas amostrais alternativos.

## 9. Amostragem de Bernoulli - BE

### Plano amostral

Um plano amostral BE consiste em uma série de experimentos independentes, um para cada elemento da população. O plano atribui probabilidade igual de seleção ( $\pi$ ), e de não-seleção ( $1 - \pi$ ), a cada elemento listado no cadastro. Conseqüentemente, o tamanho da amostra, denotado por  $n_s$ , é uma variável aleatória. Sob um BE, tem-se:

$$p(s) = \pi^{n_s} (1 - \pi)^{N - n_s},$$

$$\pi_k = \pi \quad \text{e} \quad \pi_{kl} = \pi^2.$$

## Esquema amostral

Considere um valor para  $\pi$  (  $0 < \pi < 1$  ).

Denote por  $\varepsilon_1, \varepsilon_2, \varepsilon_3, \dots, \varepsilon_N$ , uma série de  $N$  realizações de uma Uniforme(0,1).

Se  $\varepsilon_k < \pi$ , então, o elemento  $k$  é selecionado para compor  $s$ . Do contrário,  $k \notin s$ .

## Estimação

Considere a estimação do total populacional de uma população finita, sob um plano BE.

**Resultado 9.1:** Sob um plano BE, o estimador de H-T assume a forma

$$\hat{t}_{\pi} = \pi^{-1} \sum_{k \in s} y_k$$

e tem como variância

$$Var_{BE}(\hat{t}_{\pi}) = \left( \frac{1}{\pi} - 1 \right) \sum_{k \in U} y_k^2.$$

Um estimador centrado de  $Var_{BE}(\hat{t}_{\pi})$  é dado por

$$\hat{Var}_{BE}(\hat{t}_{\pi}) = \frac{1}{\pi} \left( \frac{1}{\pi} - 1 \right) \sum_{k \in U} y_k^2.$$

**Prova:**

Exercício.

Os planos AAS, AS e BE, vistos até o momento, possuem a característica comum de atribuir probabilidade igual de seleção para as amostras.

Em alguns livros, os planos que compartilham essa característica são chamados de “EPSEM”, abreviação de *Equal Probability SElection Methods*.

Na prática, porém, planos que permitem probabilidades desiguais de seleção são freqüentes. A seguir, serão vistos alguns desses planos.

## 10. Amostragem de Poisson - POI

### Plano amostral

O plano amostral POI é uma generalização do plano BE, uma vez que permite a utilização de probabilidades diferentes de seleção (e de não-seleção) para cada elemento  $k$  listado no cadastro. Denotando por  $\pi_k$  a probabilidade de seleção do elemento  $k$ , tem-se:

$$p(s) = \prod_{k \in s} \pi_k \prod_{k \in (U-s)} (1 - \pi_k).$$

Sob um POI,

$$\pi_{kl} = \pi_k \pi_l.$$

## Esquema amostral

Considere dados os valores  $\pi_k$  para  $k = 1, 2, \dots, N$ .

Denote por  $\varepsilon_1, \varepsilon_2, \varepsilon_3, \dots, \varepsilon_N$ , uma série de  $N$  realizações de uma Uniforme(0,1).

Se  $\varepsilon_k < \pi_k$ , então, o elemento  $k$  é selecionado para compor  $s$ . Do contrário,  $k \notin s$ .

Da mesma forma que no plano BE, sob um POI, o tamanho de amostra, denotado por  $n_s$ , é uma variável aleatória.

## Estimação

Considere a estimação do total populacional de uma população finita, sob um plano POI.

**Resultado 10.1:** Sob um plano POI, o estimador de H-T assume a sua forma geral

$$\hat{t}_{\pi} = \sum_{k \in s} \frac{y_k}{\pi_k}$$

e tem como variância

$$Var_{POI}(\hat{t}_{\pi}) = \sum_{k \in U} \left( \frac{1}{\pi_k} - 1 \right) y_k^2.$$



Um estimador centrado de  $Var_{POI}(\hat{t}_\pi)$  é dado por

$$\hat{Var}_{POI}(\hat{t}_\pi) = \sum_{k \in U} \left( \frac{1}{\pi_k} - 1 \right) \left( \frac{y_k}{\pi_k} \right)^2.$$

**Prova:**

Exercício.

## Motivação para os próximos planos amostrais

Considere a seguinte micro-população, com  $N=20$  elementos:

$k$	1	2	3	4	5	6	7	8	9	10
$y_k$	<b>6</b>	<b>3</b>	<b>4</b>	<b>4</b>	<b>5</b>	<b>3</b>	<b>6</b>	<b>2</b>	<b>3</b>	<b>2</b>
$k$	11	12	13	14	15	16	17	18	19	20
$y_k$	<b>2</b>	<b>6</b>	<b>5</b>	<b>3</b>	<b>5</b>	<b>2</b>	<b>4</b>	<b>6</b>	<b>4</b>	<b>5</b>

Total de  $y_k$ : **80**

Como retirar uma amostra de tamanho  $n=5$  dessa população, de forma a ter  $Var_p(\hat{t}_\pi) = 0$  ?

## **11. Amostragem com probabilidade proporcional ao tamanho - PPT**

Uma possível solução para o problema é a seguinte:

Särndal, Swensson e Wretman (1992, págs 91-97) apresentam esquemas amostrais para implementar amostras de tamanho  $n = 1$ ,  $n = 2$  e  $n > 2$ , com probabilidade proporcional ao tamanho.