

12. Amostragem Estratificada - AE

Existe uma outra forma de retirar uma amostra da micro-população apresentada na motivação (pág. 112), de modo a satisfazer a condição imposta.

Observe que a micro-população exibe uma estrutura particular. Qual é essa estrutura ?

Plano amostral

Em um plano AE, a população sob estudo é particionada em H estratos de tamanhos N_1, N_2, \dots, N_H , respectivamente:

$$U = \bigcup_{h=1}^H U_h,$$

onde $U_h = \{k \in U : k \in \text{estrato } h\}$.

Um processo físico de aleatorização é empregado dentro de cada estrato h , independentemente, para gerar uma amostra s_h , de tamanho n_h ($h = 1, 2, \dots, H$). A amostra final (de tamanho n) é composta por todos os elementos selecionados, isto é:

$$s = \bigcup_{h=1}^H s_h,$$

com $n = \sum_{h=1}^H n_h.$

Denote por p_h o plano amostral implementado pela aleatorização imposta ao estrato h . Como as amostras s_1, s_2, \dots, s_H foram geradas independentemente, o plano AE atribui probabilidade de seleção da amostra s , dada por

$$p(s) = \prod_{h=1}^H p_h(s_h).$$

Esquema amostral

Um esquema amostral deve ser empregado para implementar cada plano escolhido p_h , dentro de cada estrato h . Embora não haja restrição imposta, via de regra, escolhe-se um único esquema aplicado a todos os estratos.

Por exemplo, um plano AE com uma amostra de Bernoulli em cada estrato.

O plano mais utilizado, dentro de estratos, é o de uma AAS. Por essa razão, chamaremos de uma amostra aleatória estratificada (AAE), uma amostra gerada pelo plano AE, com AAS em cada estrato.

Justificativas frequentes para a estratificação de uma população

- *Inferência para subpopulações.*

Muitas vezes, antes da pesquisa ir a campo, é possível identificar subpopulações para as quais desejam-se estimativas com precisões pré-especificadas. Neste caso, cada subpopulação corresponderia a um estrato.

- *Razões administrativas/custo.*

Por exemplo, imagine um levantamento de âmbito geográfico, em que o órgão responsável pela pesquisa tenha escritórios em várias

regiões, cobrindo a área total a ser investigada. Neste caso, seria natural que cada região fosse um estrato. O levantamento de campo em cada estrato seria de responsabilidade do escritório regional correspondente.

- *Razões técnicas de estimação.*

É possível ainda que, para algumas subpopulações específicas, o contexto (existência de informações auxiliares, por exemplo) indique um procedimento diferente de estimação. Nestes casos, cada subpopulação específica seria um estrato.

Estimação

Considere a estimação do total populacional de uma população finita sob um plano AE, com H estratos.

Neste caso, o parâmetro de interesse pode ser escrito como:

$$t = \sum_{h=1}^H \sum_{k \in U_h} y_k = \sum_{h=1}^H t_h$$

Resultado 12.1: Sob uma AE, com H estratos, o estimador de H-T assume a forma

$$\hat{t}_{\pi} = \sum_{h=1}^H \hat{t}_{h\pi}$$

e tem como variância

$$Var_{AE}(\hat{t}_{\pi}) = \sum_{h=1}^H Var_{p_h}(\hat{t}_{h\pi}).$$

Além disso,

$$\hat{Var}_{AE}(\hat{t}_{\pi}) = \sum_{h=1}^H \hat{Var}_{p_h}(\hat{t}_{h\pi})$$

será um estimador centrado para

$Var_{AE}(\hat{t}_{\pi})$, desde que $\hat{Var}_{p_h}(\hat{t}_{h\pi})$ seja

um estimador centrado para $Var_{p_h}(\hat{t}_{h\pi})$,

para $h = 1, 2, \dots, H$.

Prova:

EXERCÍCIO:

$$\pi_{hk} = \frac{n_h}{N_h}$$

Apresente a forma específica do estimador de H-T para um plano AAE, sua variância e um estimador centrado para a variância.

12.1 Alocação ótima, sob um plano AE

Para selecionar uma AE de tamanho n de uma população particionada em H estratos é preciso decidir quantas unidades amostrais selecionar em cada estrato.

Suponha que o custo total do levantamento amostral (C) pode ser aproximado por uma função linear do tipo:

$$C = c_0 + \sum_{h=1}^H c_h n_h . \quad (11.1)$$

O problema de alocação ótima consiste em responder a uma ou outra das seguintes perguntas pertinentes:

- a) Considerando que a verba disponível para execução do levantamento é fixa e dada por C , de que forma deve-se alocar o tamanho de amostra (permitido pelo orçamento) entre os estratos, de tal forma a minimizar a variância do estimador que planeja-se utilizar ?
- b) Considerando que, dada a importância da pesquisa, o objetivo maior é o de conseguir estimativas com determinada precisão, de que forma deve-se alocar o tamanho de amostra (necessário para atingir o grau de precisão determinado) entre os estratos, de tal forma a minimizar o custo total do levantamento, dado por C ?

Resultado 12.2: Considere um plano AE, tal que a variância do estimador de H-T assume a forma

$$Var_{AE}(\hat{t}_{\pi}) = \sum_{h=1}^H \frac{A_h}{n_h} + B = V,$$

onde A_h e B não dependem de n_h .

Assumindo a função-custo linear (11.1) para C , a alocação ótima é dada pela escolha de n_h proporcional ao fator

$$\left(\frac{A_h}{c_h} \right)^{1/2}.$$

Prova:

Como B e c_0 não dependem de n_h , o problema de alocação ótima resume-se a encontrar valores de n_h que minimizem a expressão dada por

$$\phi(n_h) = \left(\sum_{h=1}^H \frac{A_h}{n_h} \right) \left(\sum_{h=1}^H c_h n_h \right).$$

Defina $a_h = (A_h/n_h)^{1/2}$
e $b_h = (c_h n_h)^{1/2}$.

Assim, pela desigualdade de Cauchy-Schwarz,

$$\phi(n_h) = \left(\sum_{h=1}^H a_h^2 \right) \left(\sum_{h=1}^H b_h^2 \right) \geq \left(\sum_{h=1}^H a_h b_h \right)^2$$

$$\therefore \quad \phi(n_h) \geq \left(\sum_{h=1}^H (A_h c_h)^{1/2} \right)^2.$$

$\phi(n_h)$ atinge o mínimo se e somente se

$$\frac{b_h}{a_h} = n_h \left(\frac{c_h}{A_h} \right)^{1/2} = cte,$$

o que equivale a $n_h \propto \left(\frac{A_h}{c_h} \right)^{1/2}.$

■

EXERCÍCIO:

Apresente a forma específica da regra de alocação ótima para um plano AAE.

12.2 Alternativas de regras de alocação sob um plano AAE.

i. *Alocação ótima de Neyman (1934):*

Considerando o custo dentro de cada estrato fixo, isto é, $c_h = c$, para $h = 1, \dots, H$, a alocação ótima sob um plano AAE - chamada, neste caso, alocação ótima de Neyman - é dada por

$$n_h = n \frac{N_h S_{yU_h}}{\sum_{h=1}^H N_h S_{yU_h}}$$

ii. *Alocação ótima em relação a uma variável auxiliar x :*

$$n_h = n \frac{N_h S_{xU_h}}{\sum_{h=1}^H N_h S_{xU_h}}$$

iii. *Alocação proporcional ao tamanho dos estratos:*

$$n_h = n \frac{N_h}{N}$$

12.3 Eficiência de um plano AAE com alocação proporcional ao tamanho do estrato

Sob alocação proporcional ao tamanho do estrato,

$$f_h = \frac{n_h}{N_h} = \frac{n}{N} = f$$

Daí, tem-se que

$$\begin{aligned} Var_{AAE,pr}(\hat{t}_\pi) &= \sum_{h=1}^H (1-f_h) N_h^2 \frac{S_{yU_h}^2}{n_h} \\ &= (1-f) \frac{N}{n} \sum_{h=1}^H N_h S_{yU_h}^2 \\ &= (1-f) \frac{N}{n} \left(SQD + \sum_{h=1}^H S_{yU_h}^2 \right) \end{aligned}$$

onde, SQD é a soma de quadrados entre estratos de uma tabela de ANOVA.

F.V.	G.L.	S.Q.
Entre estratos	$H-1$	SQE
Dentro dos estratos	$N-H$	SQD
Total	$N-1$	SQT

$$SQE = \sum_{h=1}^H N_h (\bar{y}_{U_h} - \bar{y}_U)^2$$

$$SQD = \sum_{h=1}^H (N_h - 1) S_{yU_h}^2$$

$$SQD = (N-1) S_{yU}^2$$

$$\begin{aligned}
Var_{AAS}(\hat{t}_{\pi}) &= \sum_{h=1}^H (1-f) N^2 \frac{S_{yU}^2}{n} \\
&= (1-f) \frac{N^2}{n} \frac{SQT}{N-1} \\
&= (1-f) \frac{N^2}{n(N-1)} (SQE + SQE) \\
&= Var_{AAE,pr}(\hat{t}_{\pi}) + \\
&+ (1-f) \frac{N}{n(N-1)} \left[NSQE - \sum_{h=1}^H (N-N_h) S_{yU_h}^2 \right]
\end{aligned}$$

Daí, tem-se que o plano AAE com alocação proporcional ao tamanho do estrato é mais eficiente que um plano AAS, a menos que

$$SQE < \sum_{h=1}^H \left(1 - \frac{N_h}{N}\right) S_{yU_h}^2$$